

Documento de Referencias de Datos Externos y Uso de Inteligencia Artificial Generativa

Santiago Alberto Quiroz Pintor.

Samuel Charry Tovar.

Juan Eduardo Briceño Toro.

Juan Esteban Quiroga.

Universidad de Los Andes.

Aprendizaje de máquina 2026 - 1

23 de Mayo 2026

Proyecto de Clasificación de Textos Históricos

Referencias de Datos Externos y Uso de IA Generativa

Proyecto: Clasificación de Textos Históricos — Kaggle

1. Introducción

Este documento lista los datos externos que usamos en el proyecto y explica cómo usamos herramientas de IA generativa durante el proceso. El proyecto consistió en una competencia de Kaggle para clasificar textos históricos por décadas. La solución que mejor puntuó fue un ensemble entre XLM-RoBERTa Large y un LinearSVC con TF-IDF.

2. Conjuntos de Datos Externos

2.1 Datos de la Competencia (Kaggle)

Fuente: Kaggle — competencia de clasificación de textos históricos.

Enlace: [https://www.kaggle.com/competitions/\[nombre-de-la-competencia\]](https://www.kaggle.com/competitions/[nombre-de-la-competencia])

Licencia: Los datos son exclusivos de la competencia y no pueden redistribuirse ni usarse por fuera de ella, según los términos de Kaggle.

Descripción: El dataset tiene dos archivos: train.csv con textos etiquetados por década (columnas text y decade) y eval.csv con los textos de evaluación sin etiqueta. El conjunto de evaluación tiene 3.490 textos de distintas épocas, aproximadamente entre el siglo XV y el XIX.

2.2 Modelo Preentrenado: XLM-RoBERTa Large

Fuente: Hugging Face Model Hub.

Enlace: <https://huggingface.co/FacebookAI/xlm-roberta-large>

Licencia: MIT License. Desarrollado por Facebook AI, permite uso libre tanto académico como comercial.

Descripción: Es un transformer multilingue entrenado en más de 100 idiomas con Masked Language Modeling. Lo usamos como modelo principal para capturar semántica y contexto morfológico en los textos. Los pesos se cargaron directamente desde Hugging Face con la librería transformers.

2.3 Librerías

- PyTorch (torch): Licencia BSD modificada. <https://pytorch.org> — backend principal para el entrenamiento del transformer, manejo de GPU y precisión mixta en bfloat16.
- scikit-learn: Licencia BSD de 3 cláusulas. <https://scikit-learn.org> — se usó para el LinearSVC, calibración de probabilidades con CalibratedClassifierCV, vectorización TF-IDF y el split estratificado.
- Hugging Face Transformers: Licencia Apache 2.0. <https://github.com/huggingface/transformers> — para cargar el tokenizador y la arquitectura de XLM-RoBERTa.
- NumPy y pandas: Licencia BSD. <https://numpy.org> / <https://pandas.pydata.org> — manipulación de arrays, lectura de CSVs y manejo general de datos.
- Matplotlib: Licencia PSF. <https://matplotlib.org> — para graficar las curvas de entrenamiento y la distribución de décadas del corpus.

3. Uso de IA Generativa

A lo largo del proyecto usamos herramientas de IA generativa (modelos de lenguaje) en diferentes partes del trabajo. Acá describimos en qué consistió ese uso:

3.1 Diseño del pipeline de entrenamiento

Consultamos con IA para pensar la estructura del pipeline y entender mejor algunas técnicas como LLRD (Layer-wise Learning Rate Decay), FGM (Fast Gradient Method) y label smoothing. Las sugerencias siempre las revisamos y adaptamos nosotros antes de implementarlas.

3.2 Depuración de errores

Hubo varios momentos donde el código fallaba por cosas como rutas mal configuradas en Drive, problemas de memoria en GPU o incompatibilidades entre versiones. Usamos IA para ayudarnos a identificar el problema más rápido, pero la corrección final siempre la hicimos y verificamos nosotros.

3.3 Redacción de documentación

También nos apoyamos en IA para redactar algunos comentarios del notebook y describir los hiperparámetros. Todo lo que generó lo revisamos para que fuera técnicamente correcto y coherente con lo que realmente hicimos.

3.4 Lo que NO hizo la IA

Las decisiones de modelado, la interpretación de los resultados y las conclusiones son nuestras. La IA no generó ni modificó ningún dato de entrenamiento ni de evaluación. Su rol fue siempre de apoyo, nunca tomó decisiones por el equipo.

4. Declaración

Los datos externos se usaron respetando sus licencias y condiciones de uso. El uso de IA generativa fue transparente y acotado a tareas de apoyo, sin afectar la originalidad del trabajo. Todo el desarrollo, experimentación y análisis fue realizado por los integrantes del equipo.