

Documento de Referencias de Datos Externos y Uso de Inteligencia Artificial Generativa

Santiago Alberto Quiroz Pintor.

Samuel Charry Tovar.

Juan Eduardo Briceño Toro.

Juan Esteban Quiroga.

Universidad de Los Andes.

Aprendizaje de máquina 2026 - 1

23 de Mayo 2026

Proyecto de Clasificación de Textos Históricos

1. Introducción

El presente documento tiene como propósito detallar los conjuntos de datos externos utilizados en el desarrollo del proyecto de clasificación de textos históricos, así como describir el uso dado a herramientas de inteligencia artificial generativa durante el proceso. La competencia fue realizada a través de la plataforma Kaggle, y la solución final consistió en un ensemble de dos modelos: XLM-RoBERTa Large y un clasificador LinearSVC con representación TF-IDF.

2. Conjuntos de Datos Externos

2.1 Dataset de Entrenamiento y Evaluación (Kaggle)

Fuente: Plataforma Kaggle — competencia de clasificación de textos históricos.

Enlace: [https://www.kaggle.com/competitions/\[nombre-de-la-competencia\]](https://www.kaggle.com/competitions/[nombre-de-la-competencia])

Descripción: El conjunto de datos consiste en textos históricos anotados con su década de origen. El archivo train.csv contiene el corpus de entrenamiento etiquetado (con columnas text y decade), mientras que eval.csv corresponde al corpus de evaluación sin etiqueta, utilizado para generar el archivo de submission. En total, el conjunto de evaluación comprende 3.490 textos, abarcando décadas desde el siglo XV hasta el siglo XIX aproximadamente.

2.2 Modelo Preentrenado: XLM-RoBERTa Large

Fuente: Hugging Face Model Hub.

Enlace: <https://huggingface.co/FacebookAI/xlm-roberta-large>

Licencia: MIT License. El modelo XLM-RoBERTa Large fue desarrollado por Facebook AI y está disponible de forma pública bajo licencia MIT, lo cual permite su uso, modificación y distribución tanto en contextos académicos como comerciales.

2.3 Librerías de Código Abierto

A continuación se listan las principales librerías externas empleadas:

- PyTorch (torch): Licencia BSD modificada. Disponible en <https://pytorch.org>. Utilizada como backend de deep learning para el manejo de tensores, entrenamiento del modelo transformer y soporte de GPU con precisión mixta (bfloat16).
- scikit-learn: Licencia BSD de 3 cláusulas. Disponible en <https://scikit-learn.org>. Se usó para el clasificador LinearSVC, la calibración de probabilidades mediante CalibratedClassifierCV, la vectorización TF-IDF y el split estratificado del corpus.
- Hugging Face Transformers: Licencia Apache 2.0. Disponible en <https://github.com/huggingface/transformers>. Utilizada para cargar el tokenizador y la arquitectura de XLM-RoBERTa Large.
- NumPy y pandas: Licencia BSD. Disponibles en <https://numpy.org> y <https://pandas.pydata.org> respectivamente. Usadas para manipulación de arrays, lectura de archivos CSV y gestión general de los datos del proyecto.
- Matplotlib: Licencia PSF (Python Software Foundation). Disponible en <https://matplotlib.org>. Empleada para generar visualizaciones de las curvas de entrenamiento y la distribución de las décadas del corpus.

3. Uso de Inteligencia Artificial Generativa

Durante el desarrollo del proyecto se hizo uso de herramientas de inteligencia artificial generativa, específicamente modelos de lenguaje de gran escala (LLMs). A continuación se describe el alcance y la naturaleza de dicho uso:

3.1 Asistencia en el Diseño del Pipeline

Se utilizó IA generativa como apoyo para estructurar el pipeline de entrenamiento del modelo. En particular, se consultaron sugerencias sobre la implementación de técnicas como Layer-wise Learning Rate Decay (LLRD), Fast Gradient Method (FGM) para augmentación adversarial en

el espacio de embeddings, y label smoothing. Las ideas generadas por la IA fueron revisadas, evaluadas y adaptadas al contexto específico del problema por el equipo del proyecto.

3.2 Depuración y Resolución de Errores

En varias ocasiones se consultó con herramientas de IA generativa para identificar y corregir errores en el código, particularmente relacionados con configuraciones de rutas en Google Drive, manejo de memoria GPU y compatibilidad entre versiones de librerías. La solución final fue siempre verificada y validada manualmente.

3.3 Documentación y Redacción

Se empleó asistencia de IA generativa para mejorar la redacción de comentarios y documentación dentro del notebook, incluyendo las descripciones de hiperparámetros. El contenido fue revisado por los integrantes del equipo para asegurar su precisión técnica y coherencia con el trabajo realizado.

3.4 Limitaciones y Responsabilidad

El uso de IA generativa se limitó estrictamente a un rol de apoyo. Todas las decisiones de modelado, la interpretación de resultados y las conclusiones del proyecto son responsabilidad exclusiva del equipo. Los datos utilizados para el entrenamiento y evaluación de los modelos son los proporcionados por la competencia; en ningún momento se usó la IA generativa para generar o modificar los datos de entrada.

4. Declaración de Uso Responsable

El equipo declara que los conjuntos de datos externos fueron utilizados en cumplimiento con las licencias y términos de uso correspondientes. El uso de inteligencia artificial generativa se realizó de manera transparente y como herramienta de apoyo, sin comprometer la originalidad ni la integridad del trabajo desarrollado. Toda la implementación del código, la experimentación y el análisis de resultados fue llevado a cabo por los integrantes del equipo.